7장 기계번역 (~328p)

좌표, 기하학을 숫자로 바꾸다

기하학과 대수학

기하학: 사각형에 선을 그어 눈으로 크기를 직접비교하는방식

대수학: 공식을 이용해 수식을 풀어서 증명하는 방식

즉, **사람은 직관적인 그림(기하학)을 쉽게 이해**하는 반면, **컴퓨터는 수식과 숫자(대수학)를 계산하는 데 특화**되어 있다.

기하학의 증명은 시각적으로 비중의 차이를 줌으로 증명 가능하다.

하지만 대수학은 사람에게 어떻게 증명할까 → 클로드 섀넌이 대학원생 시절 이진법을 통해 모든 계산을 할 수 있는 디지털 논리회로의 개념을 고안.

1과 0의 차이를 만들어내는 bit 개념을 도입하고, 오늘날 32비트와 64비트를 통해 데이터를 표현했다.

1과 0에 단어를 저장하기위해서는 백터화 시킬 필요가 있습니다.

자연어 처리에서의 백터로 표현한다 → 인간의 언어를 저장하기위해서는 단어를 숫자로 저장한다는 것을 의미.

모든 단어가 숫자로 나와있으므로, 단어의 숫자를 비교하여 유사도를 확정지을 수 있다.

워드투벡 언어를 숫자로 표현

이를 이용하여 구글에서는 단어의 의미를 수치화 하는 작업을 진행하였다.

단어별로 수치를 정하는 작업을 한다.

단어	단맛	크기	둥근 정도
캐러멜	0.92	0.06	0.02
호박	0.23	0.29	0.62
태양	0.01	0.99	0.99

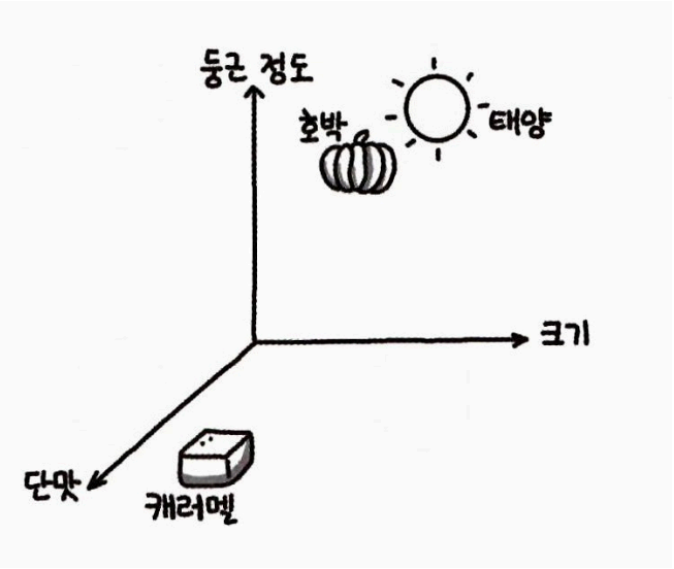

많은 단어의 특징 값을 사람이 일일이 지정할 수 없기 때문에, 워드투백은 엄청난 양의 문장 데이터를 바탕으로 컴퓨터가 스스로 값을 찾도록 학습시킨다. 문장 중간에 빈칸을 뚫어놓고 주변 단어들을 통해 빈칸에 들어갈 단어를 맞추는 방식(CBOW)을 활용한다.

원-핫 벡터에서 정교한 벡터로의 진화

초기에는 해당 단어의 위치만 '1'로 표시하고 나머지는 '0'으로 두는 단순한 '원-핫 벡터(One-Hot Vector)' 형태로 입력한다. 이후 정답 단어의 원-핫 벡터와 일치하도록 수많은 계산을 반복하며 가중치를 조절한다. 학습이 끝나면 단어는 단순한 0과 1이 아닌, 의미를 정교하게 담은 소수점 형태의 벡터 값으로 변환된다.

이렇게 학습된 워드투백 모델은 의미가 비슷한 단어일수록 벡터 공간에서 서로 가까운 숫자로 표현해 냅니다. 가장 놀라운 점은 단어 간의 관계를 수학적으로 계산할 수 있다는 것입니다. 예를 들어, '왕'에서 '남자'를 빼고 '여자'를 더하면 '여왕' 이라는 결과가 나오고, '런던'에서 '영국'을 빼고 '대한민국'을 더하면 '서울' 이라는 결과가 도출될 정도로 언어의 구조와 의미를 완벽하게 숫자로 구현해 냈다.

코사인 거리로 비슷한 단어를 찾다

단어를 벡터(숫자와 방향)로 변환한 후, **의미가 비슷한 단어를 찾기 위해 두 벡터 사이의 거리를 측정하는 계산 방식**

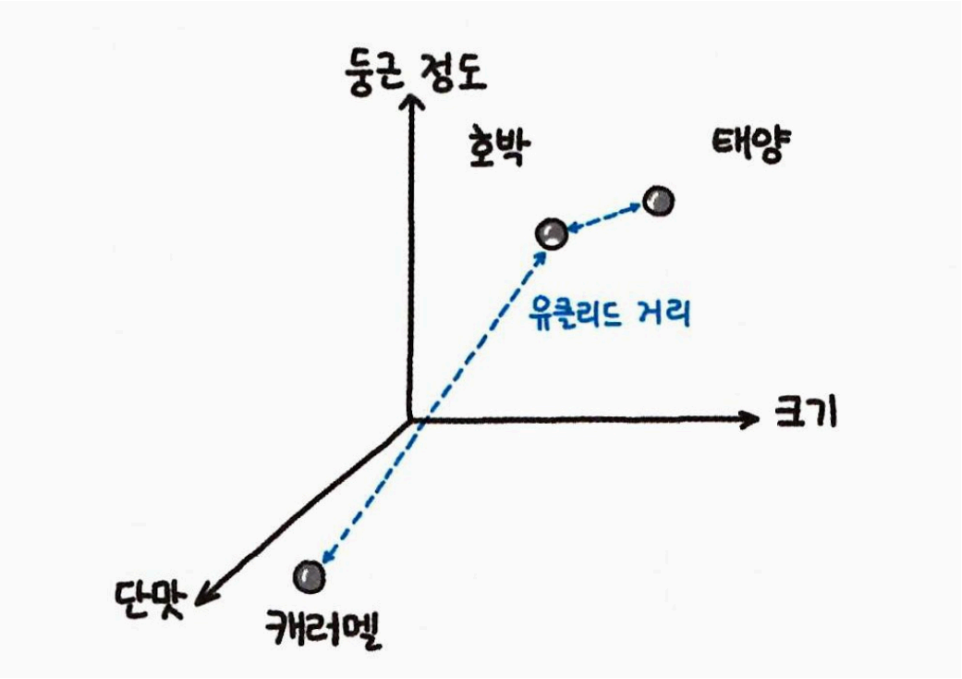

유클리드 거리(직선거리)의 한계:

가장 직관적인 방법은 두 점 사이의 직선거리인 '유클리드 거리'를 재는 것. 하지만 이 방식은 **벡터 공간의 크기(스케일)가 달라지면 계산되는 거릿값도 함께 달라진다는 치명적인 문제**가 있습니다. 예를 들어, 최댓값이 0.99인 공간과 9.99인 공간에서는 같은 단어라도 직선거리가 다르게 측정되어 일관된 유사도 판별이 어렵다.

이 크기 문제를 해결하기 위해 직선거리가 아닌 **두 벡터 사이의 '각도'를 측정**하는 방식을 사용한다.

코사인 거리의 장점:

벡터 공간의 크기가 10배, 100배로 커지더라도 **두 점이 중심과 이루는 각도는 항상 동일**합니다. 따라서 이 각도의 코사인 값을 계산하여 거리를 측정하면, 공간의 크기에 영향을 받지 않고 단어와 문장 간의 유사도를 정확하고 일관되게 판별할 수 있습니다

결과적으로 카카오뱅크 고객센터 챗봇과 같은 AI는 이 **코사인 거리 알고리즘**을 활용하여, 사용자가 입력한 질문과 가장 거리가 가까운(유사한) FAQ 질문을 데이터베이스에서 찾아내어 알맞은 답변을 자동으로 제공할 수 있게 됩니다

기계가 문장을 생성하는 방법

1. 규칙기반(템플릿기방 방식) if~ else 형태의 정해진 템플릿을 두고, 수치만 변경.
2. 딥러닝기반(엔두투엔드방식)

a. 수천만개의 영화자막같은 데이터를 통째로 입력시켜 대화의 규칙을 깨닫게 하는 end-to-end 방식을 사용.

3. 언어모델의 다음 단어 예측(GPT방식)
   a. 다음 단어가 무엇일지 확률을 계산하여 맞추는 것

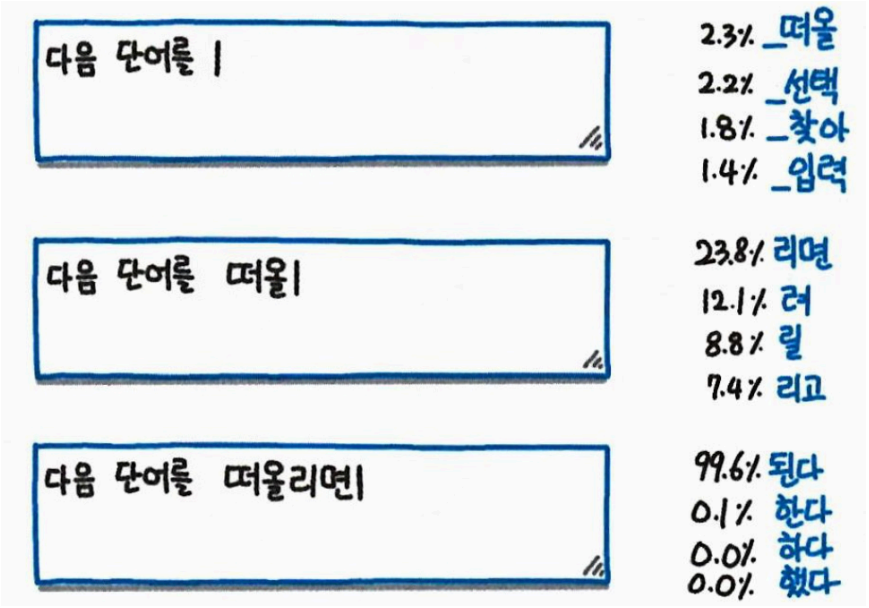

이처럼 엄청나게 많은 문장을 학습한 기계가, 현재까지 쓰인 문맥을 보고 **그다음에 올 가장 자연스러운 단어를 수학적 확률로 계산해 하나씩 이어 붙이면서** 전체 문장을 매끄럽게 완성해 내는 방식.